PitchGuard AI — Sports Science Data Requirements

Objective: Develop an AI model to estimate football players' injury risk based on injury history, physical workload and recovery indicators.

Proposed Prediction Target: Risk of a non-contact, time-loss injury within the next 7 days.

1. Required Data

Category	Key Variables	
Injury History	Injury date, injury type, body location, severity, previous injuries	
Player Information	Player ID, age, playing position	
Match & Training Exposure	Match minutes, training duration, rest days, match frequency	
External Workload	Total distance, high-speed running, sprint distance, accelerations, decelerations	
Internal Workload	Session RPE, session training load	
Recovery & Wellness	Sleep duration, fatigue, muscle soreness, HRV	

Injury History — 伤病记录

injury_id	每次伤病的唯一编号	
player_id	球员编号	
injury_start_date	伤病发生日期	
injury_end_date	伤病结束日期	
injury_type	肌肉、韧带、肌腱等损伤类型	
body_location	腘绳肌、腹股沟、踝关节等部位	
injury_mechanism	Contact / Non-contact / Unknown	
days_lost	因伤无法参加完整训练或比赛的天数	
return_to_training_date	恢复完整、不受限制的团队训练日期	

还需要从过去的记录计算 previous_injury_count 和 days_since_last_injury。

注意，不能把所有缺席都当作伤病。生病、停赛、轮休和转会导致的缺席都需要分开标记。

Match & Training Workload — 比赛和训练负荷

字段名	单位	含义
match_minutes	min	比赛出场时间
training_minutes	min	训练时长
total_distance	m	总跑动距离
hsr_distance	m	高速跑距离
sprint_distance	m	冲刺跑距离
acceleration_count	n	高强度加速次数
deceleration_count	n	高强度减速次数
max_speed	km/h	最大速度
session_rpe	0–10	训练主观用力程度
srpe_load	AU	训练时长 × session RPE

这里有两个重要的技术细节。
首先，HSR、Sprint、Acceleration 和 Deceleration 的阈值必须统一。例如 HSR 可以采用 ≥5.5 m/s 的绝对阈值，但要在数据字典中明确记录。不同供应商的默认阈值可能不同。
其次，训练数据和比赛数据最好分别保存，再计算总负荷。仅有比赛数据，会漏掉球员在周中训练所承受的负荷。

Recovery & Readiness — 恢复与准备状态

字段名	单位	说明
sleep_duration	hours	睡眠时长
sleep_quality	1–5	主观睡眠质量
fatigue_score	1–5	主观疲劳
muscle_soreness	1–5	肌肉酸痛
stress_level	1–5	压力
resting_hr	bpm	静息心率
hrv_rmssd	ms	HRV 的 RMSSD 指标

问卷必须明确方向，例如 1 = 最好还是 1 = 最差，并在整个数据集中保持一致。
HRV 是有价值的扩展指标，但不是伤病预测模型的必需数据。如果没有可穿戴设备数据，第一版可以使用 sleep、fatigue、soreness 和 sRPE。
研究支持将这些主观状态用于运动员监测，但它们与伤病的关系存在不一致性，不能简单把一次低 HRV 或睡眠不足等同于高伤病风险。

Derived Features — 从原始数据计算的特征

特征	定义
load_7d	过去 7 天累计负荷
load_28d	过去 28 天累计负荷
hsr_7d	过去 7 天高速跑总距离
sprint_7d	过去 7 天冲刺距离
load_change_pct	与前一可比较窗口相比的负荷变化率
days_since_last_match	距离上一场比赛的天数
matches_last_14d	过去 14 天比赛次数
fatigue_7d_mean	过去 7 天平均疲劳评分
individual_load_zscore	负荷相对个人历史基线的标准化偏差
acwr	急性与慢性负荷比

Data Availability

- Public data: Player information, match minutes and reported injury history.
- Usually private: GPS workload, training RPE, wellness and physiological monitoring.
- Synthetic data: Can be used to develop and demonstrate our prototype when real monitoring data are unavailable.